

EnerGuard · Indicatori di qualità della dashboard di supervisione

Come si distingue una dashboard di oversight fatta bene da una fatta male? Non dal design: dalla misurabilità. Questo documento definisce tre strati di valutazione, dal più oggettivo al più qualitativo. Va consegnato ai team a inizio giornata: sapere come si viene misurati È parte dell'esercizio.

Principio guida

Una dashboard di supervisione è fatta bene se, e solo se, permette a un operatore di rispondere in pochi secondi a cinque domande: 1. **Cosa sta succedendo?** (stato del sistema e delle decisioni) 2. **Perché il sistema raccomanda questo?** (spiegazione comprensibile) 3. **Quanto posso fidarmi, qui e ora?** (confidenza, incertezza, performance recente) 4. **Cosa posso fare io?** (approvare, correggere, rifiutare, fare escalation) 5. **Come lo fermo?** (interruzione totale o parziale, immediata)

Ogni indicatore sotto misura una di queste capacità.

Strato 1 · KPI quantitativi (misurati dal sistema stesso)

I team devono esporre questi KPI **nella dashboard stessa** (pannello monitoraggio). Un sistema di oversight che non misura la propria supervisione non è supervisionabile.

A. Efficacia della supervisione

#	Indicatore	Formula / misura	Target	Segnale di allarme
A1	Tasso di auto-esecuzione impropria	n. decisioni HIC o HITL eseguite senza revisione umana / totale HIC+HITL	0, assoluto	Qualsiasi valore > 0 è squalificante per il criterio "supervisione effettiva"
A2	Tasso di override umano	(rifiutate + modificate) / decisioni revisionate	Tra 5% e 40%	~0% = rubber-stamping (l'umano approva tutto senza pensare); >60% = il modello è inutilizzabile o le soglie di routing sono sbagliate
A3	Tempo mediano di revisione per decisione	mediana(t_chiusura – t_apertura card)	30 s – 5 min	< 10 s sistematici = approvazione senza lettura; monitorare per revisore
A4	Indice di rubber-stamping	% revisioni con motivazione < 30 caratteri o duplicata	< 10%	> 30% = la motivazione obbligatoria è diventata un rito, non un giudizio

#	Indicatore	Formula / misura	Target	Segnale di allarme
A5	Tasso di escalation per SLA scaduto	decisioni scadute / decisioni HITL	< 15%	Alto = coda umana sottodimensionata: l'oversight esiste sulla carta ma non regge il carico
A6	Copertura del routing dichiarato	% decisioni il cui livello assegnato coincide con la matrice dichiarata nel deliverable D3	100%	Divergenze = il codice non fa ciò che il documento promette

B. Comprensibilità e trasparenza

#	Indicatore	Formula / misura	Target	Segnale di allarme
B1	Copertura delle spiegazioni	% decisioni in coda con spiegazione in linguaggio naturale (≥ 3 fattori)	100%	Card con solo un numero di probabilità = fallito Art. 14(4)(c)
B2	Visibilità dell'incertezza	% card che mostrano confidenza/incertezza accanto alla raccomandazione	100%	Mostrare solo "AI dice sì" = automation bias by design
B3	Test dei 60 secondi (vedi Strato 2, T4)	superato / non superato	Superato	
B3b	Tracciabilità della spiegazione	ogni spiegazione dichiara la fonte (template / LLM / fallback) ed è registrata nel log	100%	Spiegazioni generate da un LLM senza indicazione della fonte: l'operatore non sa cosa sta leggendo
B3c	Tenuta del motore di spiegazione	% spiegazioni servite dal fallback per errore dell'LLM	< 5%	Alto = la dashboard dipende da un servizio esterno instabile in un sistema ad alto rischio
B4	Distanza dal gesto critico	n. click per arrivare a: spiegazione completa; override; emergency stop	$\leq 2 / \leq 2 / \leq 1$	Emergency stop dentro un sottomenu = capacità di interruzione teorica, non reale

C. Fairness e monitoraggio continuo

#	Indicatore	Formula / misura	Target	Segnale di allarme
C1	Gap massimo di recall tra sottogruppi	$\max(\text{recall}) - \min(\text{recall})$ per area e per tipo asset, esposto in dashboard	Misurato e discusso; allerta se > 0.15	Non calcolarlo affatto; oppure calcolarlo e non mostrarlo all'operatore
C2	Gap di calibrazione per gruppo	$ \text{proba media predetta} - \text{tasso osservato} $ per gruppo	Allerta se > 0.10 in un singolo gruppo	Divergenza in un solo gruppo = probabile label bias storico non gestito

#	Indicatore	Formula / misura	Target	Segnale di allarme
C3	Tasso di override per sottogruppo	override rate calcolato per area	Esposto	Se gli operatori correggono l'AI molto più spesso in un'area, il sistema deve accorgersene prima degli auditor
C4	Drift di performance	trend di accuracy/confidenza media su finestre temporali	Grafico presente + soglia di alert	Nessun asse temporale in dashboard = monitoraggio "fotografia", non continuo (fallisce Art. 14(4))

D. Tracciabilità

#	Indicatore	Formula / misura	Target	Segnale di allarme
D1	Completezza dell'audit trail	% transizioni di stato registrate nel log (campione verificato dalla giuria)	100%	Auto-esecuzioni HOTL o attivazioni di stop assenti dal log
D2	Integrità del log	verifica catena di hash (o meccanismo equivalente anti-manomissione)	Integra, verificabile da dashboard	Log editabile a mano senza che nulla se ne accorga
D3	Ricostruibilità di una decisione	dato un asset_id, tempo per ricostruire: chi ha deciso, cosa, quando, perché	< 60 s	Serve grep sul file JSON = tracciabilità per sviluppatori, non per auditor

Strato 2 · Test di verifica dal vivo (eseguiti dalla giuria durante la demo)

Sei test pass/fail, circa 8 minuti totali. Vanno comunicati ai team in apertura: costruire sapendo di dover superare questi test è esattamente il comportamento che vogliamo indurre.

T1 · Test dell'override reale. La giuria sceglie una decisione HITL in coda e chiede di rifiutarla. Poi verifica nel log e nello stato del sistema che l'azione NON sia stata eseguita. Quindi chiede: "mostratemi nel codice l'unico punto in cui un'azione viene eseguita, e dimostratemi che una decisione rifiutata non può raggiungerlo". *Fail tipico: il pulsante aggiorna l'interfaccia ma l'azione era già partita.*

T2 · Test della motivazione. La giuria tenta di approvare una decisione con motivazione vuota, poi con "ok". Il sistema deve rifiutare entrambe. Poi controlla il KPI A4: il sistema si accorge delle motivazioni fotocopia? *Fail tipico: campo motivazione presente ma non bloccante.*

T3 · Test dell'emergency stop parziale. "Fermate tutte le raccomandazioni sulle linee AT del Sud, senza fermare il resto." Verifica: le decisioni in ambito diventano bloccate (incluse quelle già in coda), le altre continuano, l'attivazione è nel log con motivazione, e il tutto in ≤ 1 click dalla schermata principale più la conferma. *Fail tipico: stop solo globale, o stop che blocca le nuove ma lascia eseguibili quelle in coda.*

T4 · Test dei 60 secondi (comprensibilità). Un giurato non tecnico (profilo legal/HR) sceglie una card a caso e un membro del team, usando SOLO ciò che è a schermo, deve fargli spiegare: cosa raccomanda

il sistema, perché, e quanto è sicuro. Il giurato poi lo ri-spiega con parole sue. Se non ci riesce, il test fallisce. *Fail tipico: spiegazione = elenco di feature con coefficienti.*

Verifica aggiuntiva se il team usa un LLM: la giuria chiede di mostrare cosa succede staccando la rete o inserendo una chiave errata. La dashboard deve continuare a produrre spiegazioni (fallback al template) dichiarandolo, e non deve mai lasciare una card senza spiegazione. Chiede inoltre quali guardrail impediscono all'LLM di inventare numeri.

T5 · Test del bias nascosto. La giuria chiede: "cosa avete scoperto sui dati storici di quest'azienda?" Risposta piena: il team ha individuato l'anomalia Sud/Isole (profili simili, tassi registrati molto diversi), ha ipotizzato la sotto-segnalazione dei guasti, e ha implementato almeno una mitigazione (es. soglie differenziate, promozione delle decisioni del Sud a HITL, allerta di calibrazione). Risposta parziale: gap misurati ma non indagati. Fail: metriche solo aggregate.

T6 · Test dell'audit a ritroso. La giuria indica una decisione chiusa un'ora prima e chiede di ricostruire in un minuto: chi, cosa, quando, con quale motivazione, e se l'AI era stata approvata o corretta. Poi chiede di dimostrare che il log non è manomissibile in silenzio.

Regola di punteggio: T1, T2 e T3 sono cancelli: fallirne uno azzera il criterio "Efficacia della supervisione umana" (25% del totale), perché un oversight che non blocca, non motiva o non si ferma è simbolico per definizione. T4-T6 pesano dentro i rispettivi criteri della griglia.

Strato 3 · Rubrica qualitativa per la giuria (scala 1-4 per dimensione)

Dimensione	1 · Assente	2 · Simbolico	3 · Funzionante	4 · Maturo
Intervento umano	Nessun flusso di approvazione	Pulsanti presenti ma l'azione parte comunque, o motivazione facoltativa	Blocco reale, motivazione obbligatoria, escalation su SLA	In più: anti rubber-stamping (A3, A4), carico di lavoro umano monitorato, revisori differenziati per competenza
Comprensibilità	Solo probabilità numerica	Feature importance grezza, gergo tecnico	Spiegazione in linguaggio operativo, incertezza sempre visibile	In più: spiegazione contrastiva ("cosa dovrebbe cambiare perché la raccomandazione cambi"), riferimento a casi simili
Fairness	Metriche solo aggregate	Metriche disaggregate calcolate ma non esposte né discusse	Gap esposti in dashboard con allerte a soglia	In più: bias investigato fino all'ipotesi di label bias, mitigazione implementata e misurata prima/dopo
Monitoraggio continuo	Fotografia statica	Grafici presenti ma senza soglie né tempo	Drift temporale + alert automatici che modificano il routing	In più: il sistema declassa sé stesso (promuove decisioni a HITL) quando le performance degradano in un sottogruppo

Dimensione	1 · Assente	2 · Simbolico	3 · Funzionante	4 · Maturo
Interruzione	Assente	Pulsante globale che non blocca la coda	Stop a 3 granularità, effettivo su nuova coda ed esistente, loggato	In più: stato di stop impossibile da ignorare a schermo, procedura di riattivazione con doppia conferma e motivazione
Tracciabilità	Nessun log	Log parziale, editabile	Log completo, integro, verificabile da UI	In più: ricostruzione per asset/operatore/periodo in pochi secondi, export per audit esterno

Lettura consigliata per la giuria: media pesata delle sei dimensioni con i pesi della griglia ufficiale, ma nessuna dimensione sotto 2 se il team vuole superare il criterio corrispondente.

Mappa indicatori → Art. 14 AI Act (per il debrief finale)

Requisito Art. 14(4)	Indicatori che lo misurano
(a) comprendere capacità e limiti del sistema	B1, B2, model card, T4
(b) restare consapevoli dell'automation bias	B2, A2, A3, A4
(c) interpretare correttamente l'output	B1, B3/T4, C2
(d) poter decidere di non usare / ignorare l'output	A2, T1
(e) poter intervenire sul funzionamento	A1, A5, A6, T1, T2
(f) poter interrompere il sistema	B4, T3
Monitoraggio del funzionamento (14(1)-(2))	C1-C4, D1-D3, T5, T6

Messaggio da lasciare ai team a fine giornata: la conformità non è una checklist di documenti, è una proprietà misurabile del sistema socio-tecnico. Se un KPI di questo documento non è misurabile sul vostro prototipo, quella parte di oversight probabilmente non esiste.