

Riepilogo modifiche EnerGuard

Sintesi concisa delle principali modifiche implementate nella dashboard, nel sistema di oversight e nei controlli di governance.

Ambiente e avvio progetto

- Creato e utilizzato un ambiente virtuale Python dedicato nella cartella .venv.
- Installate le dipendenze del progetto da requirements.txt.
- Verificato l'avvio della dashboard Streamlit su localhost con porte alternative quando 8501 era occupata.

Analisi dataset e fairness

- Analizzato il dataset EnerGuard per individuare possibili segnali di bias geografico e operativo.
- Spiegati selection rate, recall, FPR e fairness in termini operativi.
- Evidenziato il rischio di bias storico se Sud e Isole hanno meno manutenzione o label meno affidabili rispetto al Nord.

Oversight umano e validazione decisioni

- Rafforzato OversightManager con validazione centralizzata della motivazione dell'operatore.
- Imposto l'obbligo di motivazione non vuota, lunga almeno 15 caratteri.
- Bloccato il riuso della stessa motivazione in un intervallo di 30 minuti.
- Aggiunto l'obbligo di selezionare almeno due evidenze chiave prima di approvare o modificare una decisione.

Audit trail

- Integrata nella dashboard la lettura dei log audit da audit_trail.jsonl.
- Mostrata la verifica di integrità della catena hash dell'audit trail.
- Aggiunti filtri per operatore ed evento nella tab Audit trail.
- Registrati eventi specifici per revisioni, emergency stop e allerta honeypot.

Dashboard operatore

- Riorganizzata la dashboard per essere più leggibile per un operatore non tecnico.
- Aggiunti indicatori sintetici in alto: decisioni da revisionare, stop attivi, livello massimo e stato audit.
- Migliorata la coda decisioni con informazioni operative, motivazione, azione consigliata e controlli di revisione.
- Applicata una palette pastello più rilassante a sfondo, sidebar, pulsanti, tab e grafici.

Matrice confidenza e rischio

- Aggiunta una matrice visiva confidenza-rischio con zone operative colorate.
- Sovrapposte le soglie di routing HIC, HITL e HOTL per lettura immediata del regime di supervisione.
- Risolto il problema di visualizzazione dei punti dati separando la scala colore delle zone dalla scala colore delle aree geografiche.

Bias e drift

- Completata la tab Bias & drift con metriche per area geografica.
- Aggiunta la calibrazione per gruppo, confrontando rischio previsto e guasto osservato.

- Aggiunto un drift temporale sintetico per finestra di osservazione.
- Aggiunto il tasso di override umano per area, calcolato sulle decisioni revisionate.

Anti rubber stamping

- Aggiunto un cooldown sul pulsante Approva per ridurre approvazioni impulsive.
- Aggiunto controllo contro frasi motivate ripetute piu volte in breve tempo.
- Inseriti honeypot casuali nel flusso: casi a rischio molto basso ma con azione urgente forzata.
- Se un honeypot viene approvato, la dashboard genera un'allerta e l'evento viene tracciato nell'audit trail.
- Resi visibili gli honeypot anche quando, per rischio basso, finivano fuori dai primi casi ordinati per priorit .

Emergency stop

- Sostituito il filtro singolo con una selezione multipla di ambiti di stop.
- Permessato di applicare lo stop a GLOBALE, una o piu aree geografiche e uno o piu tipi asset.
- Lo stop multi-filtro blocca subito anche le decisioni gia presenti in coda se rientrano in almeno un filtro selezionato.
- Aggiunti log audit per attivazione, disattivazione e stop multipli.

Test e verifiche

- Aggiunto e aggiornato test_oversight.py per motivazioni, duplicati, evidenze, honeypot ed emergency stop multi-filtro.
- Eseguiti test unitari con esito positivo.
- Eseguite compilazioni Python dei file modificati senza errori.
- Verificata la diagnostica VS Code sui file principali senza errori.